

DDPM

核心算法



Algorithm 1 Training

```


1: repeat
2:    $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 
3:    $t \sim \text{Uniform}(\{1, \dots, T\})$ 
4:    $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:   Take gradient descent step on
        $\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2$ 
6: until converged
    
```

Algorithm 2 Sampling

```

1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 
    
```

想像中 ...



實際上 ...

$$\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon = \text{input}$$


ground truth

Inference

Algorithm 2 Sampling

```

1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 
    
```



噪声，保证结果有效。



sample a noise?!

$\bar{\alpha}_1, \bar{\alpha}_2, \dots, \bar{\alpha}_T$
 $\alpha_1, \alpha_2, \dots, \alpha_T$

预测噪声，而非预测图像

Conditional Diffusion Model

A cat in the snow input



在策略生成，或者说模仿学习中，有如下分类


一个目标多个条件

- ① 显示策略：直接观测映射到动作。但精度很差，且解决不了多峰性问题
- ② 隐式策略：基于观测和动作学习能量函数做优化。但是解决不了负采样的问题
- ③ Diffusion Policy：端到端的训练，直接建模动作分布的梯度场

依赖负采样

不方便，归一化系数也有

需要训练数据



改写一下DDPM

DDPM公式：

$$x^{k-1} = \alpha(x^k - \gamma \epsilon_\theta(x^k, k) + \mathcal{N}(0, \sigma^2 I))$$

$$\mathcal{L} = \text{MSE}(\epsilon^k, \epsilon_\theta(x^0 + \epsilon^k, k))$$

图像观测 → 动作序列

Diffusion Policy：

$$A_t^{k-1} = \alpha(A_t^k - \gamma \epsilon_\theta(O_t, A_t^k, k) + \mathcal{N}(0, \sigma^2 I))$$


$$\mathcal{L} = \text{MSE}(\epsilon^k, \epsilon_\theta(O_t, A_t^0 + \epsilon^k, k))$$

搞明白DDPM，Diffusion Policy易如反掌

- ① 输出从图像变成了机器人的动作
- ② 去噪的过程中输入观测O作为条件

观测数据不是联合分布，而是条件分布

Input: Image Observation Sequence



Output: Action Sequence

好在哪里

Diffusion model的优点：

- ① 能表示任意的归一化分布，可以很好的解决多峰性问题
- ② 由Autoregressive的性质，让它可以在高维空间做长序列规划
- ③ 直接由目标分布得到，规避了在非目标分布中进行负采样的问题，保证训练稳定

直接从数据中进行学习
又可以生成复杂但具有
结构化的动作



还结合了一些control的思想
和diffusion的理论

Diffusion Policy的贡献：


- ① 结合了receding-horizon control（类似MPC）做到闭环且实时的动作序列
- ② 视觉变成了生成条件的一部分而不是输入下的联合分布
- ③ 搭建了CNN和Transformer两种架构，可以适配不同的任务

视觉只做条件引导，不参与决策，决策扩散生成。模型只扩散生成动作A，不扩散图像

Close-loop action-sequence prediction



加入了类似滚动时域优化的概念




预测 T_p , 只执行 A_t

然后周而复始

神经网络架构



一维时序CNN, 用FiLM来进行特征输入



带噪动作作为token, 迭代次数作为第一个token

观测O用MLP转化为特征输入

CNN-based:

- ① 相对来说超参稳定
- ② 但是高频动作变化下, 效果就不行了

Transformer-based:

- ① 复杂任务和高频动作下效果很好
- ② 但是很难训练

Diffusion policy的性质

(位置控制) → 输出目标/速度/角度

动作的多峰性: Diffusion model的随机采样过程和随机初始化会导致动作的多峰化。


Diffusion model采取随机优化的方法, 让生成结果可以收敛到不同的动作模式上



Diffusion Policy



LSTM-GMM



BET



IBC

输出线/角速度

位置控制 vs 速度控制:

- 位置控制有更好的多模态性质
- 速度控制更容易被复合误差影响
- 位置控制能够更好的预测动作序列

动作生成的关键:

一致性: 前后动作是有联系的动作序列

平稳性: 动作生成是丝滑的, 尤其是静止动作, 例如液体倾倒

快速反应: 有较强的鲁棒性

Diffusion policy的性质



训练稳定性:

从理论上属于隐式策略的IBC可以跟diffusion policy达到一样的效果, 但是其训练非常不稳定, 原因是隐式策略的动作分布依赖于一个EBM:

$$p_{\theta}(\mathbf{a}|\mathbf{o}) = \frac{e^{-E_{\theta}(\mathbf{o}, \mathbf{a})}}{Z(\mathbf{o}, \theta)} \quad \longrightarrow \quad \mathcal{L}_{\text{InfoNCE}} = -\log\left(\frac{e^{-E_{\theta}(\mathbf{o}, \mathbf{a})}}{e^{-E_{\theta}(\mathbf{o}, \mathbf{a})} + \sum_{j=1}^{N_{\text{neg}}} e^{-E_{\theta}(\mathbf{o}, \tilde{\mathbf{a}}^j)}}\right)$$

负采样的准确性依赖于采样的质量, 若负样本无法充分覆盖动作空间, 会导致对归一化常数的估计偏差, 进而引发训练不稳定

Diffusion policy: 我直接求导, 建模动作梯度, 这下稳定了

$$\nabla_{\mathbf{a}} \log p(\mathbf{a}|\mathbf{o}) = -\nabla_{\mathbf{a}} E_{\theta}(\mathbf{a}, \mathbf{o}) - \underbrace{\nabla_{\mathbf{a}} \log Z(\mathbf{o}, \theta)}_{=0} \approx -\varepsilon_{\theta}(\mathbf{a}, \mathbf{o})$$

维度	DDPM 原版	iDDPM (Improved DDPM) 训练更高效	DDIM
改动对象	完整基础框架	训练 + 正向噪声调度	推理采样算法
噪声调度	Linear 线性	Cosine 余弦 (DP 训练选用)	复用训练时任意 schedule
反向方差	固定不可学	网络可学习方差	方差可调超参 η
采样步数	必须 1000 步, 慢	同 DDPM 原生采样很慢	可压缩至 10~100 步, 极速 可跳步采样
随机性	每步必加噪声, 随机生成	原生采样仍随机	$\eta=0$ 可完全确定
和 DP 关系	原生调度效果差被弃用	DP 训练标准方案	DP 推理加速必备
兼容性	训练权重可直接用 DDIM 采样	训练权重完美适配 DDIM	兼容 DDPM/iDDPM 训练出的网络