


1. RT-2模型基本信息


- RT-2模型将互联网规模的数据训练的vision language model集成到端到端(end-to-end)的vision language action model.
- 是一种视觉语言动作模型(VLA)，从网络数据和机器人数据中学习
- VLMs take one or more images as input, and produces a sequence of tokens that, conventionally, represent natural language text
- VLMs的应用场景有visual question answering, image captioning等
- RT-2模型的Backbone网络(核心结构模块)
 - Pathways Language and Image model (PaLI-X)
 - Pathways Language model Embodied (PaLM-E)
- representing actions as tokens in the model's output – similar to language tokens – and describe actions as strings that can be processed by standard natural language tokenizers, input and output spaces of such models don't need to be changed.



把机器人动作当成语言，
用VLM生成动作。

2. RT-2模型基本信息

- RT-2 architecture and training
 - We co-fine-tune a pre-trained VLM model on robotics and web data. The resulting model takes in robot camera images and directly predicts actions for a robot to perform.
 - web data(Internet Scale VQA)
 - robot action data
 - RT-1预测的变量的绝对动作
 - RT-2预测动作连续变化的增量



用这两个联合微调。

输出目标位置。

5. RT-2 模型基本信息

RT-2 机器人动作微调

- 将动作表示为模型输出中的Token，这些Token与语言Token的处理方式完全相同
- 基于RT-1模型提出的离散化方案进行动作编码：
 - 动作空间包括机器人末端执行器的6自由度位置和旋转位移
 - 以及机器人夹爪的伸展程度和一个用于终止episode的特殊离散命令
 - 连续维度（除终止命令外的所有维度）被均匀离散化为256个区间
- 将动作向量转换为单个字符串：只需将每个维度的动作Token用空格连接起来

PaLI-X: 0到1000的整数都有对应的唯一Token，所以我们直接将动作区间与代表对应整数的Token关联

PaLM-E模型：由于它不提供这种方便的数字表示方式，我们直接将256个最不常用的Token覆盖，用于表示动作词汇表

- 训练VLM用动作Token覆盖现有Token，这本质上是一种符号微调 (Symbol Tuning)

"terminate Δpos_x Δpos_y Δpos_z Δrot_x Δrot_y Δrot_z gripper_extension".


Open VLA 框架

动作向量

离散化

Token序列

字符串



6. RT-2模型尝试回答的几个问题

实验部分

RT-2通过实验主要回答了以下几个核心问题:

1. RT-2在已知任务上的表现如何? 更重要的是, 它在面对新物体、新背景和新环境时的泛化能力怎么样?
2. 我们能否观察并量化RT-2的涌现能力?
3. 泛化能力如何随参数量和其他设计决策变化?
4. RT-2能否像视觉语言模型一样, 展现出思维链推理的迹象?

8. RT-2模型尝试回答的几个问题

• 实验 (Experiments)

- 我们能否观察并衡量 RT-2 的涌现能力 (emergent capabilities)?
 - 模型能够通过从互联网数据中迁移知识, 实现在机器人数据中未曾演示过的新能力。我们将此类能力称为“涌现能力”。
 - RT-2 继承 (继承自大规模视觉-语言预训练) 了在场景理解中的语义理解和基础推理方面的新颖能力。

afy “把草莓放进正确的碗里” (put strawberry into the correct bowl)

- 结合场景进行推理 (reasoning in the context of the scene), 以判断草莓应该与同类水果放在一起 (like fruits)。
- “拿起快要桌子上掉落的袋子” (pick up the bag about to fall off the table)
- 通过理解来区分两个袋子, 并识别出放置不稳的物体 (understanding to disambiguate between two bags and recognize the precariously placed object)。

可理解并执行更复杂更高任务