


核心洞察：RTC = Inpainting



三个区域，三种处理方式：

区域	位置	含义	权重 W_i
Frozen	前 d 步	推理期间已执行，锁死为旧值	1
Intermediate	$d \sim H - s$ 步	有重叠，鼓励一致但允许更新	指数递减
New	后 s 步	旧 chunk 无覆盖，全新生成	0

$$W_i = \begin{cases} 1 & \text{if } i \leq d \\ c_i \frac{e^{c_i} - 1}{e - 1} & \text{if } d < i < H - s + 1 \\ 0 & \text{if } i \geq H - s + 1 \end{cases}$$
$$c_i = \frac{H - s - i}{H - s - d + 1}$$

总结

RTC 的核心贡献

- **零训练修改**：直接加在任意 diffusion/flow VLA 上即可使用
- **Inpainting 框架**：三区域设计，soft masking 保持 chunk 间策略一致
- **延迟鲁棒**：+200ms 注入延迟下吞吐量**完全不变**
- **精度提升**：消除推理暂停本身改善了动作质量（划火柴实验）

局限性

- 推理时 RTC 每步需要 VJP $\rightarrow$ 计算开销约 $2\times$ （训练时版本已解决）
- 仅适用于 diffusion/flow 模型，不适用于 autoregressive VLA（如 $\pi 0$ -FAST）
- 真实实验以双臂操作为主，腿式机器人等高动态场景待验证

展望

随模型规模增大、推理上云、支持更多机器人类型，延迟只会更高。

RTC 这个方向的价值只会越来越重要，下期继续追踪 $\pi 0.6$ 的进展