

核心洞察：多样化上下文是关键

不只告诉机器人"做什么"，还要告诉它"怎么做"

传统训练: "pick up the cup" → 动作序列

π0.7 训练:

```
任务指令: "pick up the oven mitt"
子任务指令: "grasp the handle with the left hand"
元数据: Quality: 5/5 | Speed: 2000 | Mistake: false
控制模式: joint control / end-effector control
视觉子目标: [当前帧子目标图像]
```

为什么这样有效?

- 同一段数据可以从多个角度"打标签" → **数据复用率大幅提升**
- 次优数据 (失败、低速) 用元数据标注后**不再是噪声**，而是有价值的信息
- 测试时灵活组合 prompt → 引导模型输出期望行为

架构概览：π0.7 的结构



三大组件 (共 5B 参数)

- **VLM 骨干**: 4B 参数, 基于 Gemma3, 理解视觉和语言
- **MEM 视频编码器**: 含 400M 视觉编码器, 对历史帧做时空压缩, 输出固定 token 数
- **流匹配动作专家**: 860M 参数, 每次预测 50 步动作 chunk

推理时的两级系统

- **高层策略** (同架构 VLA): 自动生成子任务语言指令
- **世界模型** (BAGEL 14B 微调): 生成视觉子目标图像

多模态 Prompt 详解

prompt 的五个维度

- **Observation**: 多帧历史观测图像
- **Task Instruction**: 整体任务的语言描述
- **Subtask Instruction**: 当前子步骤的语言描述
- **Subgoal Image**: 子步骤结束时的目标画面
- **Metadata**: Quality / Speed / Mistake 标记

关键设计: Dropout

训练时每个组件随机丢弃 → 测试时可任意组合

- 只有语言指令? 可以
- 加上子目标图像? 性能更好
- 加上元数据控制速度? 精确引导

世界模型：视觉子目标生成

用图像告诉机器人"这步结束时应该长这样"

$$\max_{\psi} \mathbb{E}_{D_g} \left[\mathcal{L}_{CFM} \left(g_t^*, g_{\psi}(o_t, \hat{\ell}_t, m) \right) \right]$$

- g_t^* : 训练段末帧（真实子目标图像）
- o_t : 当前观测
- $\hat{\ell}_t$: 子任务指令
- m : 元数据

世界模型特点

- 基于 **BAGEL**（14B MoT 图像生成模型）微调
- 用 **web 数据 + 人类视频** 增强，获得丰富物理先验
- 训练时混合使用真实未来帧（25%末帧 + 75%往后0-4秒随机帧）和生成帧

子目标图像比语言指令**更精确地**描述空间关系，显著提升泛化性